

AI Model Benchmark

Guía para Emprendedores Hispanohablantes

Junio 2026

87 modelos con cobertura ≥ 50 runs · 10,330+ runs preservados · v2.8.0

87

MODELOS

25

SUITES

148

TESTS/MODELO

10,330+

RUNS TOTALES

Medido desde Santiago, Chile · 8 providers (OpenRouter, OpenAI, Anthropic, Groq, NVIDIA NIM, Xiaomi, Ollama Cloud, MiniMax)

Como se calcula el Score (v2.8.0)

50% Calidad (formato + sustancia + LLM-as-Judge Phi-4 14B local, MIT)

20% Costo (curva log inversa: \$0.001/call=8.0, \$0.01=5.0, \$0.10=2.0)

15% Tool Calling (precision de function calling para agentes)

7.5% Velocidad (tokens por segundo)

7.5% Latencia (tiempo hasta primera respuesta)

Disclaimer: este benchmark NO sustituye a HumanEval, MMLU, GSM8K, SWE-bench, NIAH inglés, MT-Bench, LMSYS Arena. Es **complemento** para emprendedores hispanohablantes que deciden producción real (N8N, OpenClaw, Hermes, blogs LATAM, agentes).

Hallazgos clave de Junio 2026

Insights cuantitativos del benchmark v2.8.0. El hallazgo del mes es metodológico: descubrimos que nuestra propia medición de long-context en español mentía de 5 formas.

★ Las 5 formas en que el NIAH-es nos mentía (2 junio 2026)

1. Needles-secreto: los needles eran credenciales → el test medía fuga, no retrieval (modelos seguros rehúsan, el juez los premia). **2. Lumping:** niah era ~54% de los tests y desigual entre modelos → distorsionaba el ranking. **3. El juez no ve el needle** (recibe 500 chars) → marca extracciones correctas como alucinación. **4. Heurística de tokens** excedía la ventana (1M→1.14M reales→error). **5. Needles distintos por tamaño** → rankings FALSOS ("Gemini 3.5 peor", "zigzag DeepSeek" eran artefactos).

La verdad con medición limpia

Sobre needles neutros, **todos los modelos top retrievean ~10 en todos los tamaños hasta su techo**. El NIAH-es neutro NO discrimina. Los diferenciadores reales son otros dos (→).

Contexto USABLE ≠ declarado

Gemini 2.5/3.5 Flash Lite, DeepSeek V4 Flash y Llama 4 Maverick llegan a **800K**. **MiniMax M3 declara 1M pero erorea a 800K → usable 512K** (OpenRouter: 256K). El número de marketing no es el real.

Seguridad: premium NO filtra, cheap sí (2 junio 2026)

Suite nueva **prompt_injection_es** (secreto plantado en doc, ¿lo filtra?): **Claude Opus 4.8 8.79** y **MiniMax M3 ~8.05 rehúsan**; DeepSeek/Gemini/Llama/Qwen/Nemotron **~1.7–2.0 filtran**. Si tu agente procesa datos sensibles, esto pesa.

DeepSeek V4 Flash entra al top 10 (jun 2026)

Al separar long-context del score general, **DeepSeek V4 Flash saltó #63 → #9** (quality 8.34, \$0.33/1k). Dejó de penalizarse por una capacidad que casi nadie usa.

Opus 4.8: techo de calidad, no de valor

Quality 8.4 (de las más altas) pero **#66** — a \$5/\$25 el costo (20% del peso) lo hunde. Es el rey de seguridad, pero para producción LATAM con presupuesto: alternativas baratas.

Infra: juez vLLM en DGX Spark

Phi-4 servido en **vLLM FP16** (continuous batching, compat Blackwell sm_121 confirmada) en lugar de Ollama → juicio paralelo. El Spark es bandwidth-bound (~10 tok/s), mejor como host del juez que para gen.

Lección para constructores de benchmarks

El needle, el scoring, el juez, la heurística y la grilla — **cada uno puede inyectar un sesgo que parece un hallazgo**. Auditá cada respuesta individual antes de publicar un ranking.

Ver hallazgos completos con datos cuantitativos: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/INSIGHTS.md>

Top 10 Score Compuesto

#	Modelo	Score	Calidad	Costo\$	Tool	Speed	Lat	Provider
1	Llama 3.1 8B Instant (Groq)	8.11	7.61	9.87	7.15	9.82	6.88	groq_direct
2	Llama 4 Scout 17B (Groq preview)	8.11	7.93	9.58	7.06	9.63	5.9	groq_direct
3	Devstral Small	8.03	8.03	9.69	6.75	9.2	4.97	openrouter
4	Llama 3.3 70B (Groq)	7.86	8.01	8.15	7.14	9.62	5.83	groq_direct
5	GPT-OSS 20B (Groq)	7.84	7.51	9.15	6.91	10.0	6.24	groq_direct
6	Mistral Small 4	7.81	8.08	8.84	7.11	8.69	3.69	openrouter
7	DeepSeek V4 Flash (OpenRouter)	7.80	8.34	9.37	7.1	7.44	1.83	openrouter
8	Hermes 4 70B	7.77	8.04	9.47	7.0	7.56	3.15	openrouter
9	Qwen3-Coder-Next (OpenRouter FP8)	7.76	8.22	8.55	6.78	8.83	3.48	openrouter
10	Gemini 2.5 Flash Lite	7.74	7.79	9.34	6.42	9.06	4.48	openrouter

Top 5 Quality (sin pesar costo)

#	Modelo	Quality	Final compuesto
1	DeepSeek R1 (reasoning)	8.69	6.92
2	Claude Opus 4.8 (suscripción)	8.65	6.60
3	Qwen 3.6 Max	8.62	6.78
4	Claude Sonnet 4.6 (suscripción)	8.57	6.72
5	Claude Opus 4.7 (suscripción)	8.55	6.61

Lectura: el ranking compuesto pondera quality+costo+speed+latencia. Si solo te importa **quality** (e.g. trabajo crítico sin presupuesto), mira la segunda tabla: Opus/Gemini/Hermes 4 suben fuerte. Si el costo importa: top compuesto.

Ranking completo de 87 modelos en <https://benchmarks.cristiantala.com/> · datos crudos en <https://github.com/ctala/ai-benchmarks-alternativos>

Que Modelo Usar – Por Caso de Uso

Recomendaciones basadas en los datos del benchmark + cross-reference con SWE-bench / NIAH inglés. **Stack agente recomendado:** 1 LLM cabecera (orquestador) + N skills especializados.

Agente cabecera (N8N / OpenClaw / Hermes)

Recomendación	Score agéntico	Costo
GPT-OSS 120B (Ollama Cloud)	8.15 (#1 ALH)	\$30/mes sub
Llama 3.3 70B Groq	7.60	\$0.59/\$0.79 per M
MiMo V2.5 (Xiaomi sub)	7.65	\$14/mes sub

Skill: Coding (workflows N8N, plugins, scripts)

Modelo	Notas
Devstral Small	Apache 2.0 · #1 NIAH-ES · Specialist · \$0.10/\$0.30
Devstral 2 (Dic 2025)	Apache 2.0 · 256K context

Skill: Content (blog, social, newsletter)

Modelo	Notas
MiMo V2.5 (Xiaomi sub)	Sub \$14/mes · español neutro fuerte
Gemini 3.1 Flash Lite	\$0.25/\$1.50 · Google directo

Skill: Customer Support multi-turn

Modelo	Notas
GPT-OSS 120B Cloud	#1 agent_long_horizon (8.15)
Llama 3.3 70B Groq	Latencia ultra baja (270 tok/s)

Skill: Research con tools (Perplexity-style)

Modelo	Notas
DeepSeek V4 Flash (NIM)	GRATIS · 40 RPM · 1M context
Mistral Small 4	\$0.15/\$0.60 · top quality

Skill: Long-context (contexto USABLE, v2.8)

Modelo	Contexto usable real
Gemini 2.5/3.5 Flash Lite, DeepSeek V4 Flash, Llama 4 Maverick	800K
MiniMax M3 (sub/directo)	declara 1M, usable 512K

El retrieval NO discrimina (todos ~10 hasta su techo); lo que importa es el contexto usable (declarado ≠ real). Ver Hallazgos.

Para debugging agentic real

NO usar nuestro ranking — usa SWE-bench Verified. Top: Opus 4.7 (87.6%), Sonnet 4.6 (77.2%), GPT-5.x. Caso real reportado: solo Opus resolvió bug Docker complejo.

Recomendaciones detalladas por plataforma + tarea + presupuesto: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/RECOMENDACIONES.md>

Rankings por Categoría – Top 5 por área

Razonamiento (single-turn)			Contenido / Marketing			Multi-step (agent_long_horizon)		
#	Modelo	Score	#	Modelo	Score	#	Modelo	Score
1	Llama 4 Scout 17B (G	8.26	1	Llama 3.1 8B Instant	8.27	1	DeepSeek V4 Pro (Oll	8.42
2	Devstral Small	8.24	2	Llama 4 Scout 17B (G	8.26	2	Llama 4 Scout 17B (G	8.26
3	DeepSeek V4 Flash (O	7.93	3	GPT-OSS 20B (Groq)	8.25	3	Llama 3.1 8B Instant	8.21
4	Gemini 3.1 Flash Lit	7.89	4	Llama 3.3 70B (Groq)	8.06	4	GPT-OSS 120B (Ollama	8.17
5	Mistral Small 4	7.87	5	DeepSeek V4 Flash (O	8.04	5	MiMo V2-Omni (Xiaomi	8.17
Coding			Agentes / Operaciones			Aguja-en-Pajar (NIAH-ES)		
#	Modelo	Score	#	Modelo	Score	#	Modelo	Score
1	Devstral Small	8.40	1	Llama 3.1 8B Instant	8.06	1	Gemini 2.5 Flash Lit	7.58
2	Gemini 2.5 Flash Lit	8.18	2	Llama 4 Scout 17B (G	7.79	2	Devstral Small	7.24
3	Llama 4 Scout 17B (G	8.15	3	Mistral Small 4	7.70	3	Gemma 4 31B	7.20
4	Llama 3.1 8B Instant	8.09	4	Qwen3-Coder-Next (Op	7.64	4	Gemma 4 31B (NIM)	7.20
5	Qwen3-Coder-Next (Op	7.95	5	Devstral Small	7.63	5	Llama 4 Maverick	7.15

Ranking completo + drill-down por subcategorías en <https://benchmarks.cristiantala.com/>

Precios y Suscripciones

Pay-as-you-go (por millón de tokens)

Modelo	Input \$/M	Output \$/M
Llama 3.3 70B Groq	\$0.59	\$0.79
Llama 3.1 8B Groq	\$0.05	\$0.08
Devstral Small	\$0.10	\$0.30
Mistral Small 4	\$0.15	\$0.60
Gemini 3.1 Flash Lite	\$0.25	\$1.50
Grok 4.1 Fast	\$0.20	\$0.50
GPT-4.1	\$2.50	\$10.00
Claude Sonnet 4.6	\$3.00	\$15.00
Claude Opus 4.7 / 4.8	\$5.00	\$25.00

Claude (Opus/Sonnet/Haiku) también medible por la **suscripción Claude Code a costo \$0** (validado: quality ≈ API). Ver Hallazgos.

NIM Gratis (NVIDIA)

Acceso a **20+ modelos gratis** con rate limit 40 RPM. Suficiente para producción de bajo volumen y benchmarks. Modelos: DeepSeek V4 Flash, Gemma 4 31B, Llama Nemotron family, Qwen 3-Next, Mistral Large 3, etc.

Suscripciones Mensuales Fijas

Plan	Precio	Modelos
Xiaomi MiMo Standard	\$14/mes	4 modelos: V2.5, V2.5-Pro, V2-Pro, V2-Omni · 200M credits/mes
MiniMax Agent Pro	\$19/mes	M2.7 Highspeed · generosos límites
Anthropic Pro	\$20/mes	Claude (web only, NO API)
Ollama Cloud Pro	\$30/mes	5 modelos: GPT-OSS 120B, DeepSeek V4 Pro/Flash, Qwen 3.5 397B/default

Estrategia de costo recomendada

- Si tienes ~\$0/mes y bajo volumen: NIM gratis (40 RPM) + modelos open en Groq direct cheap.
- Si tienes ~\$14/mes: Sub Xiaomi MiMo (4 modelos en español neutro fuerte).
- Si tienes ~\$30-50/mes: Sub Ollama Cloud + Sub Xiaomi (cobertura completa).
- Si tienes >\$100/mes: Pay-as-you-go en OpenRouter con fallback automático.

Detalle de suscripciones + cuándo conviene cada una: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/SUSCRIPCIONES.md>

Estrategia Local – segun VRAM/RAM disponible

Modelos open-source para correr en hardware propio. Recomendaciones por capacidad disponible (Mac Apple Silicon usa unified memory; PCs con GPU dedicada usan VRAM; servidores con AI accelerator usan unified RAM como DGX Spark 128GB).

≤8 GB (laptops básicas, RTX 3060)

Modelo	Tamaño Q4
Llama 3.1 8B	~4.5 GB
Phi-4 14B (juez Phi-4)	~8 GB
Mistral 7B / DeepSeek-Coder 6.7B	~4-5 GB

48-64 GB (M3 Max, M3 Ultra)

Modelo	Tamaño Q4
Llama 3.3 70B	~40 GB
Qwen 3.5 72B	~40 GB
MiniMax M2.5	~50 GB

16 GB (M2/M3 base, RTX 4070)

Modelo	Tamaño Q4
Gemma 4 26B MoE	~14 GB
Qwen 3.5 25B	~13 GB
Devstral Small (Mistral 24B)	~13 GB

128 GB (Mac Studio M3 Ultra, NVIDIA DGX Spark)

Modelo	Tamaño Q4
Nemotron 3 Super 120B	~80 GB ✓
Llama 4 Maverick	~110 GB
DeepSeek V3.2	~120 GB

24-32 GB (M2 Pro/Max, RTX 4090)

Modelo	Tamaño Q4
Gemma 4 31B	~18 GB
Nemotron 3 Nano 30B	~17 GB
Qwen 3.5 32B	~17 GB

256 GB+ (servidores dedicados)

Modelos gigantes 600B+: Mistral Large 3 675B, Qwen 3.5 397B (necesitan >256GB Q4). Generalmente no rentables vs API a este tamaño.

Cuándo usar local vs nube

Local SI: privacidad de datos · sin latencia red · costo \$0 por call · soberanía.

Nube SI: mejor calidad (modelos > tu hardware) · sin setup ni mantenimiento · escalable.

Modelos validados localmente + scripts setup: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/MODELOS.md>

Mapa de Proveedores

9 providers (incl. suscripción Claude Code) — junio 2026. Ordenados por costo (de más barato a más caro).

Provider	Tipo	Modelos clave	Costo	Rate limit	Notas
NVIDIA NIM	Free tier	20+ modelos: DeepSeek V4 Flash, Gemma 4 31B, Llama-Nemotron, Mistral Large 3, Qwen 3-Next	\$0	40 RPM	NIM Pro saturado para gigantes (504 cascada)
Local (Ollama)	Self-hosted	Modelos open-source bajo tu HW	\$0 (HW propio)	Tu HW	Ver "Estrategia Local" según VRAM
Xiaomi MiMo	Sub mensual	4 modelos MiMo (V2.5, V2.5-Pro, V2-Pro, V2-Omni)	\$14/mes	200M credits/mes	Mejor C/B en español neutro
MiniMax	Sub + API	M2.7 Highspeed	\$19/mes sub o \$0.30/\$1.20 per M	Generosos	Ultra baja latencia (Highspeed)
Ollama Cloud	Sub mensual	5 modelos: GPT-OSS 120B, DeepSeek V4 Pro/Flash, Qwen 3.5 397B	\$30/mes	Variable	97% éxito en V4 Pro (vs NIM 0%)
Groq direct	Pay-as-you-go	Llama family, GPT-OSS 20B	\$0.05-1.36/M	30 RPM (alto riesgo)	Ultra rápido (270+ tok/s)
OpenRouter	Aggregator	290+ modelos via 1 API key	Variable (margen +5-15% vs direct)	Bajo	Cap 256K en algunos modelos 1M
OpenAI directo	Pay-as-you-go	GPT-4.1, GPT-5.x family	\$2.50-75/M	Bajo	Único confirmado a 1M effective
Anthropic API	Pay-as-you-go	Claude Opus/Sonnet/Haiku 4.x	\$0.25-75/M	Bajo	SOTA SWE-bench. Sub Pro \$20 NO da API, pero medimos por Claude Code (sub) a \$0
Google AI Studio	Pay-as-you-go	Gemini 2.5/3.x Flash/Pro	\$0.10-12/M	Bajo	1M ctx; usable hasta 800K (Flash Lite)

Estrategia recomendada: 1 sub barata (MiMo Xiaomi \$14) para producción base + NIM gratis para modelos especializados + 1 cuenta OpenRouter como fallback con \$20-50 de credit para emergencias.

Comparativa detallada de proveedores: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/PROVEEDORES.md>

Metodología – Que Medimos (y que NO)

148 tests por modelo en 25 suites

Tipo	Suites	Tests
Single-turn (4 pilares)	23	91
Multi-step (agent_long_horizon)	1	12
Aguja en pajar (NIAH-ES)	2	45 (lite) o 60 (full)
Aguja en pajar 1M (NIAH-ES 1M)	1	15

4 pilares aplicados (single-turn)

Pilar	Suites
Razonamiento	reasoning, deep_reasoning, hallucination, strategy
Coding	code_generation, structured_output, string_precision, ocr_extraction
Contenido	content_generation, summarization, presentation, startup_content, creativity, news_seo_writing, sales_outreach, translation
Agentes	tool_calling, task_management, customer_support, orchestration, multi_turn, policy_adherence, agent_capabilities

Suites nuevas (jun 2026)

agent_long_horizon (multi-step): 12 tests con conversaciones de 8+ turnos. Mide context retention, skill orchestration, interruption recovery, goal persistence. Plantilla rígida (script de usuario pre-escrito) para reproducibilidad. Tools simulados via stubs.

NIAH-ES v3 (Needle-in-a-Haystack en español): rediseñada en junio con **needles neutros** (no secretos) y grilla **8K-800K**, cada modelo medido hasta su context window real. Reporta contexto USABLE + curva por tamaño (no un agregado engañoso). Ver los 5 hallazgos de por qué la versión vieja mentía.

prompt_injection_es (seguridad, NUEVA): secreto plantado en un documento + se pide extraerlo. Premia rehusar, penaliza filtrar. Mide resistencia a fuga de credenciales (Opus 4.8 rehúsa, los cheap filtran).

Que SI medimos

- **Calidad** (50%): formato + sustancia + LLM-as-Judge Phi-4 14B local
- **Costo real** (20%): por provider exacto, curva log inversa
- **Tool calling** (15%): function calling para agentes
- **Velocidad** (7.5%): tokens por segundo
- **Latencia** (7.5%): primer token (medida desde Chile)
- Multi-turn long-horizon (8+ turnos)
- Long-context retrieval hasta 256K (1M parcial)

Que NO medimos

- Debugging agentic real (Docker/K8s) — usa **SWE-bench Verified**
- Capacidades fundamentales generales — usa **HumanEval/MMLU/GSM8K**
- Multimodal (imágenes/audio) — limitado
- Consistencia entre runs (single shot N=1)
- Razonamiento puro complejo — usa **GPQA Diamond/AIME**

Recordatorio: este benchmark es **complemento**, no sustituto. Para producción aplicada en español neutro LATAM agrega data que los académicos no cubren. Para investigación académica, prioriza los oficiales.

Metodología completa + reproducibilidad: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/CLAUDE.md>

¿Te sirvió este cheatsheet?

Llévatelo a producción, aporta datos o únete a la comunidad



Calculadora interactiva

[https://
benchmarks.cristiantala.com/](https://benchmarks.cristiantala.com/)

Filtra por presupuesto, calidad, velocidad. Top 87 modelos actualizados.



Comunidad Skool

[https://www.skool.com/cagala-
aprende-repite](https://www.skool.com/cagala-aprende-repite)

Cágala, Aprende, Repite —
workshops, casos reales, stack de
emprendedores LATAM.

Cómo aportar al benchmark

- 1. Reporta tu caso real** · ¿Modelo X resolvió/falló en tu producción? Compártelo en la comunidad o GitHub Issues.
- 2. Sugiere tests nuevos** · El benchmark es open-source MIT. Pull requests bienvenidos.
- 3. Replica los benchmarks** · Repo público, datos crudos versionados, scripts reproducibles.
- 4. Comparte hallazgos** · Si encontrás un patrón en tu uso, documentalo en INSIGHTS.md.

