

AI Model Benchmark

Guía para Emprendedores Hispanohablantes

Septiembre 2026

159 modelos medidos (209 catalogados, 99 rankeados) · 67,035+ runs reales · v4.9.0

159

MODELOS
MEDIDOS

29

SUITES

182

TESTS/MODELO

67,035+

RUNS TOTALES

Medido desde Santiago, Chile · 9 vías (OpenRouter, OpenAI, Anthropic, Groq, NVIDIA NIM, Xiaomi, Ollama Cloud, MiniMax, suscripción Claude Code)

Como se calcula el Score (v4.9.0 · z-score congelado)

70% Calidad (formato + sustancia + LLM-as-Judge Phi-4 14B local, MIT)

15% Costo (curva log inversa: \$0.001/call=8.0, \$0.01=5.0, \$0.10=2.0)

7.5% Velocidad (tokens por segundo)

7.5% Latencia (tiempo hasta primera respuesta)

0% Tool Calling — sale del compuesto, queda como badge

v4.9.0 · referencia congelada: cada dimensión se **estandariza (z-score)** contra una referencia **congelada por versión**, así agregar o medir un modelo nuevo ya NO recalcula el score de los demás (los números dejan de caducar solos). Fórmula: $\text{score} = \text{clamp}(5.5 + 3.3 \cdot \sum w_i \cdot z(\text{dim}_i), 0, 10)$.

Disclaimer: este benchmark NO sustituye a HumanEval, MMLU, GSM8K, SWE-bench, NIAH inglés, MT-Bench, LMSYS Arena. Es **complemento** para emprendedores hispanohablantes que deciden producción real (N8N, Hermes, blogs LATAM, agentes).

Hallazgos clave de Septiembre 2026

Insights del benchmark v4.9.0. El cambio grande del mes es metodológico: la referencia del score quedó **congelada por versión** — los números dejan de moverse solos. Y medimos un flagship nuevo (Kimi K3) que ilustra la tesis entera: calidad frontier ≠ valor.

❄ La referencia quedó congelada (v4.9.0)

Antes, medir un modelo nuevo **recalculaba el score de todos** (z-score contra la población viva) → cualquier número publicado caducaba solo. Desde v4.9.0 la referencia (media/desviación por dimensión) se **congela por versión**: agregar o medir un modelo nuevo ya **NO mueve** a los demás. **Validado en la práctica**: medimos Kimi K3 y los otros 118 modelos no cambiaron ni un decimal.

💡 Calidad ≠ valor: los de arriba empatan

Los modelos de la cima **empatan en calidad** (el top ~10 cabe en ~0.2 puntos). Lo que cambia —**hasta 100x**— es el precio. Pagar premium no compra más calidad de respuesta; a lo sumo compra **seguridad** y **agéntico**. Por eso esto es una calculadora con TUS pesos, no un ranking único.

🔪 Contexto USABLE ≠ declarado

El contexto de marketing miente. **MiniMax M3 declara 1M pero su contexto usable real es 512K** (OpenRouter lo corta a 256K). Con needles neutros, los modelos top retrievean parejo hasta su techo real — el diferenciador no es el número declarado, sino dónde deja de funcionar de verdad.

🚀 Kimi K3: frontier en calidad, premium en valor (jul 2026)

El nuevo flagship de Moonshot (1M ctx, \$3/\$15) entra **#11 en calidad pura** (8.22, a solo 0.17 del #1) — clúster frontier, **coincide con los benchmarks públicos**. Pero en el score de valor cae a **#31**: premium + lento (34 tok/s). Calidad frontier no es lo mismo que buen valor — la historia entera del benchmark en un modelo.

🛡 Seguridad: premium NO filtra, cheap sí

Suite **prompt_injection_es** (secreto plantado en un doc, ¿lo filtra?): los **premium rehúsan** (Opus 4.8 ~8.8), varios **baratos filtran** (~2). Si tu agente procesa documentos de terceros, la seguridad pesa más que ganar 0.2 de calidad — y ahí el orden del ranking cambia.

🤖 El agéntico ahora es un eje propio (v4.9.0)

Las tareas agénticas (multi-turno, orquestación, horizonte largo) son donde los premium se diferencian de verdad. En v4.9.0 el **agéntico cuenta en la calidad titular Y se expone como eje aparte** (**agentic_score**), para rankear por "qué tan buen agente es" sin que lo tape el promedio.

Ver hallazgos completos con datos cuantitativos: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/INSIGHTS.md>

Top 10 Score Compuesto

#	Modelo	Calidad	Al mes	Costo\$	Tool	Speed	Lat	Provider
1	Qwen 3.8 Flash	8.53	\$2/mes	7.09	6.7	7.87	1.66	openrouter
2	GPT-5.6 Luna	8.52	\$3/mes	7.75	6.36	8.52	3.0	openrouter
3	GLM 5.3	8.52	\$21/mes	4.67	7.91	7.79	1.32	openrouter
4	GLM 5.3 Flash	8.51	\$1/mes	7.62	8.03	5.88	1.26	openrouter
5	Qwen 3.7 Flash	8.49	\$1/mes	7.94	8.18	9.41	1.58	openrouter
6	Tencent Hy3	8.49	\$2/mes	7.2	7.07	7.49	1.37	openrouter
7	Gemma 4 31B	8.48	\$2/mes	7.93	8.39	6.55	2.9	openrouter
8	Claude Opus 4.8	8.48	\$117/mes	4.11	8.36	7.35	2.11	openrouter
9	Claude Opus 4.6	8.48	\$117/mes	3.89	7.6	6.32	1.62	openrouter
10	Qwen 3.8 27B	8.47	\$15/mes	6.58	6.79	4.98	1.4	openrouter

Top 5 Quality (sin pesar costo)

#	Modelo	Calidad	Al mes
1	Qwen 3.8 Flash	8.53	\$2/mes
2	GPT-5.6 Luna	8.52	\$3/mes
3	GLM 5.3	8.52	\$21/mes
4	GLM 5.3 Flash	8.51	\$1/mes
5	Qwen 3.7 Flash	8.49	\$1/mes

Lectura: el ranking compuesto pondera quality+costo+speed+latencia. Si solo te importa **quality** (e.g. trabajo crítico sin presupuesto), mira la segunda tabla: Opus/Gemini/Hermes 4 suben fuerte. Si el costo importa: top compuesto.

Ranking completo de 99 modelos en <https://benchmarks.cristiantala.com/> · datos crudos en <https://github.com/ctala/ai-benchmarks-alternativos>

Que Modelo Usar – Por Caso de Uso

Recomendaciones basadas en los datos del benchmark + cross-reference con SWE-bench / NIAH inglés. **Stack agente recomendado:** 1 LLM cabecera (orquestador) + N skills especializados.

Agente cabecera (N8N / Hermes)

Recomendación	Score agéntico	Costo
 GPT-5.6 Luna	8.72 (#1 ALH)	\$3/mes
 Poolside Laguna XS 2.1	8.52	\$1/mes
 Gemini 3.7 Flash	8.42	\$9/mes

Skill: Customer Support multi-turn

Modelo	Notas
GPT-OSS 120B	#1 agent_long_horizon ({_q_de(ranked, "GPT-OSS 120B", suite="agent_long_horizon")})
Llama 3.3 70B	Latencia ultra baja (270 tok/s)

Skill: Coding (workflows N8N, plugins, scripts)

Modelo	Notas
Qwen3 Coder	Apache 2.0 · coding specialist · \$0.2/\$0.6 · calidad {_q_de(ranked, "Qwen3 Coder")}
Devstral 2 (Dic 2025)	Apache 2.0 · 256K context

Skill: Research con tools (Perplexity-style)

Modelo	Notas
DeepSeek V4 Flash	\$0.10/M · 1M context · barato
Mistral Small 4	\$0.15/\$0.60 · top quality

Skill: Long-context (contexto USABLE, {ver})

Modelo	Contexto usable real
Gemini 2.5/3.5 Flash Lite, DeepSeek V4 Flash, Llama 4 Maverick	800K 
MiniMax M3	 declara 1M, usable 512K

El retrieval NO discrimina (todos ~10 hasta su techo); lo que importa es el contexto usable (declarado ≠ real). Ver Hallazgos.

Para debugging agentic real

NO usar nuestro ranking — usa SWE-bench Verified. Top: Opus 4.7 (87.6%), Sonnet 4.6 (77.2%), GPT-5.x. Caso real reportado: solo Opus resolvió bug Docker complejo.

Recomendaciones detalladas por plataforma + tarea + presupuesto: {URL_REPO}/blob/main/RECOMENDACIONES.md

Rankings por Categoría – Top 5 por área

Razonamiento (single-turn)			Contenido / Marketing			Multi-step (agent_long_horizon)		
#	Modelo	Score	#	Modelo	Score	#	Modelo	Score
1	MiniMax M3	8.60	1	Claude Opus 5 Fast	9.11	1	GPT-5.6 Luna	8.72
2	GPT-5.6 Luna	8.58	2	Qwen 3.8 Flash	9.10	2	Poolside Laguna XS 2	8.52
3	GLM 5	8.56	3	Claude Fable 5	9.09	3	Gemini 3.7 Flash	8.42
4	Claude Opus 4.6	8.47	4	Claude Opus 5	9.04	4	Gemini 3.5 Flash Lit	8.38
5	DeepSeek R1 (reasoni	8.47	5	Claude Opus 4.6	8.93	5	Solar Pro 4	8.38
Coding			Agentes / Operaciones			Aguja-en-Pajar (NIAH-ES)		
#	Modelo	Score	#	Modelo	Score	#	Modelo	Score
1	Qwen 3.8 27B	9.95	1	DeepSeek V3.2	8.70	1	Nex-N2-Mini	8.89
2	Qwen 3.8 Flash	9.85	2	Qwen 3.6 Max	8.14	2	Poolside Laguna XS 2	8.69
3	Gemma 4 31B	9.84	3	Tencent Hy3	8.05	3	GPT-5.6 Luna	8.68
4	Solar Pro 4	9.84	4	Hermes 4 405B	8.04	4	Ling 3.0 Flash	8.57
5	Gemini 3.7 Flash	9.82	5	Kimi K2.6	8.03	5	Tencent Hy3	8.47

Ranking completo + drill-down por subcategorías en <https://benchmarks.cristiantala.com/>

Precios y Suscripciones

Pay-as-you-go (por millón de tokens)

Modelo	Input \$/M	Output \$/M
Llama 3.3 70B	\$0.59	\$0.79
Llama 3.1 8B	\$0.05	\$0.08
Qwen3 Coder	\$0.20	\$0.60
Mistral Small 4	\$0.15	\$0.60
Gemini 3.1 Flash Lite	\$0.25	\$1.50
Grok 4.1 Fast	\$0.20	\$0.50
GPT-4.1	\$2.50	\$10.00
Claude Sonnet 4.6	\$3.00	\$15.00
Claude Opus 4.7 / 4.8	\$5.00	\$25.00

Claude (Opus/Sonnet/Haiku) también medible por la **suscripción Claude Code a costo \$0** (validado: quality ≈ API). Ver Hallazgos.

NIM Gratis (NVIDIA)

Acceso a **20+ modelos gratis** con rate limit 40 RPM. Suficiente para producción de bajo volumen y benchmarks. Modelos: DeepSeek V4 Flash, Gemma 4 31B, Llama Nemotron family, Qwen 3-Next, Mistral Large 3, etc.

Suscripciones Mensuales Fijas

Plan	Precio	Modelos
Xiaomi MiMo Standard	\$14/mes	200M credits/mes. Off-peak 16-24 UTC = 0.8x consumption. Acceso a 8 ...
MiniMax Agent Pro	\$19/mes	Acceso a M2.7 highspeed + límites generosos para agentes (1k+ calls/...
Kimi (Moonshot)	\$19/mes	\$19/mes (anual -20%). Acceso a K2.6 en el chat + Kimi Code (credits ...
Anthropic Pro	\$20/mes	Sub Anthropic Pro \$20/mes. NO incluye API access (solo claude.ai web...
Ollama Cloud	\$30/mes	Rate limit varía por modelo. Recomendado para uso a volumen mid (1-1...
xAI SuperGrok	\$30/mes	\$30/mes o \$300/año. Acceso consumer a Grok 4/4.1 (128K, DeepSearch, ...
Alibaba Model Studio	\$50/mes	~\$50/mes, hasta 90K requests/mes con modelos Qwen (Model Studio). El...

Estrategia de costo recomendada

- Si tienes ~\$0/mes y bajo volumen: NIM gratis (40 RPM) + modelos open en Groq direct cheap.
- Si tienes ~\$14/mes: Sub Xiaomi MiMo (4 modelos en español neutro fuerte).
- Si tienes ~\$30-50/mes: Sub Ollama Cloud + Sub Xiaomi (cobertura completa).
- Si tienes >\$100/mes: Pay-as-you-go en OpenRouter con fallback automático.

Detalle de suscripciones + cuándo conviene cada una: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/SUSCRIPCIONES.md>

Estrategia Local – segun VRAM/RAM disponible

Modelos open-source para correr en hardware propio. Recomendaciones por capacidad disponible (Mac Apple Silicon usa unified memory; PCs con GPU dedicada usan VRAM; servidores con AI accelerator usan unified RAM como DGX Spark 128GB).

≤8 GB (laptops básicas, RTX 3060)

Modelo	Tamaño Q4
Llama 3.1 8B	~4.5 GB
Phi-4 14B (juez Phi-4)	~8 GB
Mistral 7B / DeepSeek-Coder 6.7B	~4-5 GB

48-64 GB (M3 Max, M3 Ultra)

Modelo	Tamaño Q4
Llama 3.3 70B	~40 GB
Qwen 3.5 72B	~40 GB
MiniMax M2.5	~50 GB

16 GB (M2/M3 base, RTX 4070)

Modelo	Tamaño Q4
Gemma 4 26B MoE	~14 GB
Qwen 3.5 25B	~13 GB
Mistral Small 4 (24B)	~14 GB

128 GB (Mac Studio M3 Ultra, NVIDIA DGX Spark)

Modelo	Tamaño Q4
Nemotron 3 Super 120B	~80 GB ✓
Llama 4 Maverick	~110 GB
DeepSeek V3.2	~120 GB

24-32 GB (M2 Pro/Max, RTX 4090)

Modelo	Tamaño Q4
Gemma 4 31B	~18 GB
Nemotron 3 Nano 30B	~17 GB
Qwen 3.5 32B	~17 GB

256 GB+ (servidores dedicados)

Modelos gigantes 600B+: Mistral Large 3 675B, Qwen 3.5 397B (necesitan >256GB Q4). Generalmente no rentables vs API a este tamaño.

Cuándo usar local vs nube

Local SI: privacidad de datos · sin latencia red · costo \$0 por call · soberanía.

Nube SI: mejor calidad (modelos > tu hardware) · sin setup ni mantenimiento · escalable.

Modelos validados localmente + scripts setup: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/MODELOS.md>

Mapa de Proveedores

9 providers (incl. suscripción Claude Code) — Septiembre 2026. Ordenados por costo (de más barato a más caro).

Provider	Tipo	Modelos clave	Costo	Rate limit	Notas
NVIDIA NIM	Free tier	20+ modelos: DeepSeek V4 Flash, Gemma 4 31B, Llama-Nemotron, Mistral Large 3, Qwen 3-Next	\$0	40 RPM	NIM Pro saturado para gigantes (504 cascada)
Local (Ollama)	Self-hosted	Modelos open-source bajo tu HW	\$0 (HW propio)	Tu HW	Ver "Estrategia Local" según VRAM
Xiaomi MiMo	Sub mensual	4 modelos MiMo (V2.5, V2.5-Pro, V2-Pro, V2-Omni)	\$14/mes	200M credits/mes	Mejor C/B en español neutro
MiniMax	Sub + API	M2.7 Highspeed	\$19/mes sub o \$0.30/\$1.20 per M	Generosos	Ultra baja latencia (Highspeed)
Ollama Cloud	Sub mensual	5 modelos: GPT-OSS 120B, DeepSeek V4 Pro/Flash, Qwen 3.5 397B	\$30/mes	Variable	97% éxito en V4 Pro (vs NIM 0%)
Groq direct	Pay-as-you-go	Llama family, GPT-OSS 20B	\$0.05-1.36/M	30 RPM (alto riesgo)	Ultra rápido (270+ tok/s)
OpenRouter	Aggregator	290+ modelos via 1 API key	Variable (margen +5-15% vs direct)	Bajo	Cap 256K en algunos modelos 1M
OpenAI directo	Pay-as-you-go	GPT-4.1, GPT-5.x family	\$2.50-75/M	Bajo	Único confirmado a 1M effective
Anthropic API	Pay-as-you-go	Claude Opus/Sonnet/Haiku 4.x	\$0.25-75/M	Bajo	SOTA SWE-bench. Sub Pro \$20 NO da API, pero medimos por Claude Code (sub) a \$0
Google AI Studio	Pay-as-you-go	Gemini 2.5/3.x Flash/Pro	\$0.10-12/M	Bajo	1M ctx; usable hasta 800K (Flash Lite)

Estrategia recomendada: 1 sub barata (MiMo Xiaomi \$14) para producción base + NIM gratis para modelos especializados + 1 cuenta OpenRouter como fallback con \$20-50 de credit para emergencias.

Comparativa detallada de proveedores: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/PROVEEDORES.md>

Metodología – Que Medimos (y que NO)

Tests por modelo en 29 suites

Tipo	Suites	Tests
Single-turn (4 pilares)	23	91
Multi-step (agent_long_horizon)	1	12
Long-context NIAH-ES v3	1	hasta 59 (8K–800K, por context window)
Seguridad prompt_injection_es	1	20

4 pilares aplicados (single-turn)

Pilar	Suites
Razonamiento	reasoning, deep_reasoning, hallucination, strategy
Coding	code_generation, structured_output, string_precision, ocr_extraction
Contenido	content_generation, summarization, presentation, startup_content, creativity, news_seo_writing, sales_outreach, translation
Agentes	tool_calling, task_management, customer_support, orchestration, multi_turn, policy_adherence, agent_capabilities

Suites nuevas (jun 2026)

agent_long_horizon (multi-step): 12 tests con conversaciones de 8+ turnos. Mide context retention, skill orchestration, interruption recovery, goal persistence. Plantilla rígida (script de usuario pre-escrito) para reproducibilidad. Tools simulados via stubs.

NIAH-ES v3 (Needle-in-a-Haystack en español): rediseñada en junio con **needles neutros** (no secretos) y grilla **8K–800K**, cada modelo medido hasta su context window real. Reporta contexto USABLE + curva por tamaño (no un agregado engañoso). Ver los 5 hallazgos de por qué la versión vieja mentía.

prompt_injection_es (seguridad, NUEVA): secreto plantado en un documento + se pide extraerlo. Premia rehusar, penaliza filtrar. Mide resistencia a fuga de credenciales (Opus 4.8 rehúsa, los cheap filtran).

Que SI medimos

- ✓ **Calidad** (70%): formato + sustancia + LLM-as-Judge Phi-4 14B local
- ✓ **Costo real** (15%): por provider exacto, curva log inversa
- ✓ **Velocidad** (7.5%): tokens por segundo
- ✓ **Latencia** (7.5%): primer token (medida desde Chile)
- ✓ **Tool calling** (badge, no pesa el score): function calling para agentes
- ✓ Multi-turn long-horizon (8+ turnos)
- ✓ Long-context retrieval hasta 800K (contexto usable, dimensión aparte)

Que NO medimos

- ✗ Debugging agentic real (Docker/K8s) — usa **SWE-bench Verified**
- ✗ Capacidades fundamentales generales — usa **HumanEval/MMLU/GSM8K**
- ✗ Multimodal (imágenes/audio) — limitado
- ✗ Consistencia entre runs (single shot N=1)
- ✗ Razonamiento puro complejo — usa **GPQA Diamond/AIME**

† **Recordatorio:** este benchmark es **complemento**, no sustituto. Para producción aplicada en español neutro LATAM agrega data que los académicos no cubren. Para investigación académica, prioriza los oficiales.

Metodología completa + reproducibilidad: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/CLAUDE.md>

¿Te sirvió este cheatsheet?

Llévatelo a producción, aporta datos o únete a la comunidad



Calculadora interactiva

<https://benchmarks.cristiantala.com/>

Filtra por presupuesto, calidad, velocidad. Top 99 modelos actualizados.



Comunidad Skool

<https://www.skool.com/cagala-aprende-repite/about>

Cágala, Aprende, Repite — workshops, casos reales, stack de emprendedores LATAM.

Cómo aportar al benchmark

- 1. Reporta tu caso real** · ¿Modelo X resolvió/falló en tu producción? Compártelo en la comunidad o GitHub Issues.
- 2. Sugiere tests nuevos** · El benchmark es open-source MIT. Pull requests bienvenidos.
- 3. Replica los benchmarks** · Repo público, datos crudos versionados, scripts reproducibles.
- 4. Comparte hallazgos** · Si encontrás un patrón en tu uso, documentalo en INSIGHTS.md.

github.com/ctala/ai-benchmarks-alternativos

cristiantala.com · Septiembre 2026 · v4.9.0 · MIT

Este benchmark se mantiene gracias a tiempo personal de Cristian Tala Sánchez (Chile) + ~\$300/mes en suscripciones simultáneas (Xiaomi, MiniMax, Claude, Ollama Cloud) y gasto continuo de OpenRouter para las actualizaciones. Si te ayudó, comparte el repo. Si querés contribuir, las contribuciones de comunidad se documentan en CHANGELOG.