

AI Model Benchmark

Guía para Emprendedores Hispanohablantes

Septiembre 2026

160 modelos medidos (210 catalogados, 100 rankeados) · 67,275+ runs reales · v4.13.0

160

MODELOS
MEDIDOS

29

SUITES

182

TESTS/MODELO

67,275+

RUNS TOTALES

Medido desde Santiago, Chile · 9 vías (OpenRouter, OpenAI, Anthropic, Groq, NVIDIA NIM, Xiaomi, Ollama Cloud, MiniMax, suscripción Claude Code)

Como se calcula el Score (v4.13.0 · z-score congelado)

70% Calidad (formato + sustancia + LLM-as-Judge Phi-4 14B local, MIT)

15% Costo (curva log inversa: \$0.001/call=8.0, \$0.01=5.0, \$0.10=2.0)

7.5% Velocidad (tokens por segundo)

7.5% Latencia (tiempo hasta primera respuesta)

0% Tool Calling — sale del compuesto, queda como badge

v4.13.0 · referencia congelada: cada dimensión se **estandariza (z-score)** contra una referencia **congelada por versión**, así agregar o medir un modelo nuevo ya NO recalcula el score de los demás (los números dejan de caducar solos). Fórmula: $\text{score} = \text{clamp}(5.5 + 3.3 \cdot \sum w_i \cdot z(\text{dim}_i), 0, 10)$.

Disclaimer: este benchmark NO sustituye a HumanEval, MMLU, GSM8K, SWE-bench, NIAH inglés, MT-Bench, LMSYS Arena. Es **complemento** para emprendedores hispanohablantes que deciden producción real (N8N, Hermes, blogs LATAM, agentes).

Hallazgos clave de Septiembre 2026

Lo que muestran los datos de v4.13.0, con 100 modelos que rindieron el examen completo. El hallazgo del mes se puede probar dentro de una misma familia, que es donde no cabe la réplica de «son modelos distintos».



La versión cara dejó de comprar calidad

Que un barato le gane a un caro siempre admite el reproche de «son modelos distintos». Este mes pasa **dentro de la misma familia: Qwen 3.6 Max** saca 8.46 y cuesta \$29/mes; **Qwen 3.7 Flash** saca 8.49 y cuesta \$1/mes. Una diferencia de 0.03 por **47x el precio**.



Arriba están todos empatados

El top 10 entero cabe en **0.06 puntos**, y del primero al último de los 100 hay 1.27. La calidad está apretada; el precio no. Por eso esto es una calculadora con TUS pesos y no un ranking único: leer la tabla por posición engaña cuando la distancia real es de centésimas.



Contexto USABLE ≠ declarado

El contexto de marketing miente: **42 de los 100 rankeados entregan menos de lo que declaran**. El caso más extremo hoy es **Muse Spark 1.2**, que anuncia 1M y en la práctica sostiene 128K. Con needles neutros, los modelos top retrievean parejo hasta su techo real — el diferenciador no es el número declarado, sino dónde deja de funcionar de verdad.



Lo que entró este mes

Sin modelos nuevos en el ranking desde el release anterior. El #1 del catálogo es **Qwen 3.8 Flash** (8.53) y cuesta \$2 al mes: **lo barato dejó de ser la opción de compromiso**, hoy es la que encabeza.



Seguridad: premium NO filtra, cheap sí

Suite **prompt_injection_es** (secreto plantado en un doc, ¿lo filtra?): los **premium rehúsan** (Opus 4.8 ~8.8), varios **baratos filtran** (~2). Si tu agente procesa documentos de terceros, la seguridad pesa más que ganar 0.2 de calidad — y ahí el orden del ranking cambia.



El agéntico ahora es un eje propio (v4.13.0)

Las tareas agénticas (multi-turno, orquestación, horizonte largo) son donde los premium se diferencian de verdad. En v4.13.0 el **agéntico cuenta en la calidad titular Y se expone como eje aparte** (**agentic_score**), para rankear por "qué tan buen agente es" sin que lo tape el promedio.

Ver hallazgos completos con datos cuantitativos: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/INSIGHTS.md>

Top 10 por calidad

#	Modelo	Calidad	Al mes	Costo\$	Tool	Speed	Lat	Provider
1	Qwen 3.8 Flash	8.53	\$2/mes	7.09	6.7	7.87	1.66	openrouter
2	GLM 5.3	8.52	\$21/mes	4.67	7.91	7.79	1.32	openrouter
3	GLM 5.3 Flash	8.51	\$1/mes	7.62	8.03	5.88	1.26	openrouter
4	GPT-5.6 Luna	8.49	\$3/mes	7.74	6.36	8.52	2.91	openrouter
5	Qwen 3.7 Flash	8.49	\$1/mes	7.94	8.18	9.44	1.55	openrouter
6	Tencent Hy3	8.49	\$2/mes	7.2	7.07	7.49	1.37	openrouter
7	Claude Opus 4.8	8.48	\$117/mes	4.11	8.36	7.35	2.11	openrouter
8	Claude Opus 4.6	8.48	\$117/mes	3.89	7.6	6.32	1.62	openrouter
9	Gemma 4 31B	8.47	\$2/mes	7.92	8.39	6.55	2.79	openrouter
10	Qwen 3.8 27B	8.47	\$15/mes	6.58	6.79	4.98	1.4	openrouter

Lo más barato que se mantiene arriba

Calidad ≥ 8,4 —el clúster de cabeza— ordenado por lo que cuesta al mes. Es la pregunta que el ranking no responde: no cuál es el mejor, sino cuál es el más barato de los que están arriba.

#	Modelo	Calidad	Al mes
1	Qwen 3.7 Flash	8.49	\$1/mes
2	GLM 5.3 Flash	8.51	\$1/mes
3	Gemma 4 31B	8.47	\$2/mes
4	Qwen 3.8 Flash	8.53	\$2/mes
5	Tencent Hy3	8.49	\$2/mes

Lectura: el ranking compuesto pondera quality+costo+speed+latencia. Si solo te importa **quality** (e.g. trabajo crítico sin presupuesto), mira la segunda tabla: Opus/Gemini/Hermes 4 suben fuerte. Si el costo importa: top compuesto.

Ranking completo de 100 modelos en <https://benchmarks.cristiantala.com/> · datos crudos en <https://github.com/ctala/ai-benchmarks-alternativos>

Que Modelo Usar – Por Caso de Uso

Recomendaciones basadas en los datos del benchmark + cross-reference con SWE-bench / NIAH inglés. **Stack agente recomendado:** 1 LLM cabecera (orquestador) + N skills especializados.

Agente cabecera (N8N / Hermes)

Recomendación	Score agéntico	Costo
 GPT-5.6 Luna	8.72 (#1 ALH)	\$3/mes
 Poolside Laguna XS 2.1	8.52	\$1/mes
 Gemini 3.7 Flash	8.42	\$9/mes

Skill: Customer Support multi-turn

Modelo	Notas
GPT-OSS 120B	#1 agent_long_horizon ({_q_de(ranked, "GPT-OSS 120B", suite="agent_long_horizon")})
Llama 3.3 70B	Latencia ultra baja (270 tok/s)

Skill: Coding (workflows N8N, plugins, scripts)

Modelo	Notas
Qwen3 Coder	Apache 2.0 · coding specialist · \$0.2/\$0.6 · calidad {_q_de(ranked, "Qwen3 Coder")}
Devstral 2 (Dic 2025)	Apache 2.0 · 256K context

Skill: Research con tools (Perplexity-style)

Modelo	Notas
DeepSeek V4 Flash	\$0.10/M · 1M context · barato
Mistral Small 4	\$0.15/\$0.60 · top quality

Skill: Long-context (contexto USABLE, {ver})

Modelo	Contexto usable real
Gemini 2.5/3.5 Flash Lite, DeepSeek V4 Flash, Llama 4 Maverick	 800K
{_peor_ctx["name"]}	declara {_k(_peor_ctx["context_window"])}, usable {_k(_peor_ctx["effective_context"])}

El retrieval NO discrimina (todos ~10 hasta su techo); lo que importa es el contexto usable (declarado ≠ real). Ver Hallazgos.

Para debugging agentic real

NO usar nuestro ranking — usa SWE-bench Verified. Top: Opus 4.7 (87.6%), Sonnet 4.6 (77.2%), GPT-5.x. Caso real reportado: solo Opus resolvió bug Docker complejo.

Rankings por Categoría – Top 5 por área

Razonamiento (single-turn)			Contenido / Marketing			Multi-step (agent_long_horizon)		
#	Modelo	Score	#	Modelo	Score	#	Modelo	Score
1	MiniMax M3	8.60	1	Claude Opus 5 Fast	9.11	1	GPT-5.6 Luna	8.72
2	GLM 5	8.56	2	Qwen 3.8 Flash	9.10	2	Poolside Laguna XS 2	8.52
3	Claude Opus 4.6	8.47	3	Claude Fable 5	9.09	3	Gemini 3.7 Flash	8.42
4	DeepSeek R1 (reasoni	8.47	4	Claude Opus 5	9.04	4	Gemini 3.5 Flash Lit	8.38
5	Claude Opus 4.8	8.46	5	Claude Opus 4.6	8.93	5	Solar Pro 4	8.38
Coding			Agentes / Operaciones			Aguja-en-Pajar (NIAH-ES)		
#	Modelo	Score	#	Modelo	Score	#	Modelo	Score
1	Qwen 3.8 27B	9.95	1	DeepSeek V3.2	8.70	1	Nex-N2-Mini	8.89
2	Qwen 3.8 Flash	9.85	2	Qwen 3.6 Max	8.14	2	Poolside Laguna XS 2	8.69
3	Gemma 4 31B	9.84	3	Tencent Hy3	8.05	3	GPT-5.6 Luna	8.68
4	Solar Pro 4	9.84	4	Hermes 4 405B	8.04	4	Ling 3.0 Flash	8.57
5	Gemini 3.7 Flash	9.82	5	Kimi K2.6	8.03	5	Tencent Hy3	8.47

Ranking completo + drill-down por subcategorías en <https://benchmarks.cristiantala.com/>

Precios y Suscripciones

Pay-as-you-go (por millón de tokens)

Modelo	Input \$/M	Output \$/M
Llama 3.3 70B	\$0.59	\$0.79
Llama 3.1 8B	\$0.05	\$0.08
Qwen3 Coder	\$0.20	\$0.60
Mistral Small 4	\$0.15	\$0.60
Gemini 3.1 Flash Lite	\$0.25	\$1.50
Grok 4.1 Fast	\$0.20	\$0.50
GPT-4.1	\$2.50	\$10.00
Claude Sonnet 4.6	\$3.00	\$15.00
Claude Opus 4.7 / 4.8	\$5.00	\$25.00

Claude (Opus/Sonnet/Haiku) también medible por la **suscripción Claude Code a costo \$0** (validado: quality ≈ API). Ver Hallazgos.

NIM Gratis (NVIDIA)

Acceso a **20+ modelos gratis** con rate limit 40 RPM. Suficiente para producción de bajo volumen y benchmarks. Modelos: DeepSeek V4 Flash, Gemma 4 31B, Llama Nemotron family, Qwen 3-Next, Mistral Large 3, etc.

Suscripciones Mensuales Fijas

Plan	Precio	Modelos
Xiaomi MiMo Standard	\$14/mes	200M credits/mes. Off-peak 16-24 UTC = 0.8x consumption. Acceso a 8 ...
MiniMax Agent Pro	\$19/mes	Acceso a M2.7 highspeed + límites generosos para agentes (1k+ calls/...
Kimi (Moonshot)	\$19/mes	\$19/mes (anual -20%). Acceso a K2.6 en el chat + Kimi Code (credits ...
Anthropic Pro	\$20/mes	Sub Anthropic Pro \$20/mes. NO incluye API access (solo claude.ai web...
Ollama Cloud	\$30/mes	Rate limit varía por modelo. Recomendado para uso a volumen mid (1-1...
xAI SuperGrok	\$30/mes	\$30/mes o \$300/año. Acceso consumer a Grok 4/4.1 (128K, DeepSearch, ...
Alibaba Model Studio	\$50/mes	~\$50/mes, hasta 90K requests/mes con modelos Qwen (Model Studio). El...

Estrategia de costo recomendada

Si tienes ~\$0/mes y bajo volumen: NIM gratis (40 RPM) + modelos open en Groq direct cheap.

Si tienes ~\$14/mes: Sub Xiaomi MiMo (4 modelos en español neutro fuerte).

Si tienes ~\$30-50/mes: Sub Ollama Cloud + Sub Xiaomi (cobertura completa).

Si tienes >\$100/mes: Pay-as-you-go en OpenRouter con fallback automático.

Detalle de suscripciones + cuándo conviene cada una: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/SUSCRIPCIONES.md>

Estrategia Local – segun VRAM/RAM disponible

Modelos open-source para correr en hardware propio. Recomendaciones por capacidad disponible (Mac Apple Silicon usa unified memory; PCs con GPU dedicada usan VRAM; servidores con AI accelerator usan unified RAM como DGX Spark 128GB).

≤8 GB (laptops básicas, RTX 3060)

Modelo	Tamaño Q4
Llama 3.1 8B	~4.5 GB
Phi-4 14B (juez Phi-4)	~8 GB
Mistral 7B / DeepSeek-Coder 6.7B	~4-5 GB

48-64 GB (M3 Max, M3 Ultra)

Modelo	Tamaño Q4
Llama 3.3 70B	~40 GB
Qwen 3.5 72B	~40 GB
MiniMax M2.5	~50 GB

16 GB (M2/M3 base, RTX 4070)

Modelo	Tamaño Q4
Gemma 4 26B MoE	~14 GB
Qwen 3.5 25B	~13 GB
Mistral Small 4 (24B)	~14 GB

128 GB (Mac Studio M3 Ultra, NVIDIA DGX Spark)

Modelo	Tamaño Q4
Nemotron 3 Super 120B	~80 GB ✓
Llama 4 Maverick	~110 GB
DeepSeek V3.2	~120 GB

24-32 GB (M2 Pro/Max, RTX 4090)

Modelo	Tamaño Q4
Gemma 4 31B	~18 GB
Nemotron 3 Nano 30B	~17 GB
Qwen 3.5 32B	~17 GB

256 GB+ (servidores dedicados)

Modelos gigantes 600B+: Mistral Large 3 675B, Qwen 3.5 397B (necesitan >256GB Q4). Generalmente no rentables vs API a este tamaño.

Cuándo usar local vs nube

Local SI: privacidad de datos · sin latencia red · costo \$0 por call · soberanía.
Nube SI: mejor calidad (modelos > tu hardware) · sin setup ni mantenimiento · escalable.

Modelos validados localmente + scripts setup: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/MODELOS.md>

Mapa de Proveedores

11 providers (incl. suscripción Claude Code) — Septiembre 2026. Ordenados por costo (de más barato a más caro).

Provider	Tipo	Modelos clave	Costo	Rate limit	Notas
NVIDIA NIM	Free tier	20+ modelos: DeepSeek V4 Flash, Gemma 4 31B, Llama-Nemotron, Mistral Large 3, Qwen 3-Next	\$0	40 RPM	NIM Pro saturado para gigantes (504 cascada)
Local (Ollama)	Self-hosted	Modelos open-source bajo tu HW	\$0 (HW propio)	Tu HW	Ver "Estrategia Local" según VRAM
Xiaomi MiMo	Sub mensual	4 modelos MiMo (V2.5, V2.5-Pro, V2-Pro, V2-Omni)	\$14/mes	200M credits/mes	Mejor C/B en español neutro
MiniMax	Sub + API	M2.7 Highspeed	\$19/mes sub o \$0.30/\$1.20 per M	Generosos	Ultra baja latencia (Highspeed)
Ollama Cloud	Sub mensual	5 modelos: GPT-OSS 120B, DeepSeek V4 Pro/Flash, Qwen 3.5 397B	\$30/mes	Variable	97% éxito en V4 Pro (vs NIM 0%)
Groq direct	Pay-as-you-go	Llama family, GPT-OSS 20B	\$0.05-1.36/M	30 RPM (alto riesgo)	Ultra rápido (270+ tok/s)
OpenRouter	Aggregator	290+ modelos via 1 API key	Variable (margen +5-15% vs direct)	Bajo	Cap 256K en algunos modelos 1M
OpenAI directo	Pay-as-you-go	GPT-4.1, GPT-5.x family	\$2.50-75/M	Bajo	Único confirmado a 1M effective
Anthropic API	Pay-as-you-go	Claude Opus/Sonnet/Haiku 4.x	\$0.25-75/M	Bajo	SOTA SWE-bench. Sub Pro \$20 NO da API, pero medimos por Claude Code (sub) a \$0
Google AI Studio	Pay-as-you-go	Gemini 2.5/3.x Flash/Pro	\$0.10-12/M	Bajo	1M ctx; usable hasta 800K (Flash Lite)

Estrategia recomendada: 1 sub barata (MiMo Xiaomi \$14) para producción base + NIM gratis para modelos especializados + 1 cuenta OpenRouter como fallback con \$20-50 de credit para emergencias.

Comparativa detallada de proveedores: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/PROVEEDORES.md>

Metodología – Que Medimos (y que NO)

Tests por modelo en 29 suites

Tipo	Suites	Tests
Single-turn (4 pilares)	23	91
Multi-step (agent_long_horizon)	1	12
Long-context NIAH-ES v3	1	hasta 59 (8K–800K, por context window)
Seguridad prompt_injection_es	1	20

4 pilares aplicados (single-turn)

Pilar	Suites
Razonamiento	reasoning, deep_reasoning, hallucination, strategy
Coding	code_generation, structured_output, string_precision, ocr_extraction
Contenido	content_generation, summarization, presentation, startup_content, creativity, news_seo_writing, sales_outreach, translation
Agentes	tool_calling, task_management, customer_support, orchestration, multi_turn, policy_adherence, agent_capabilities

Suites nuevas (jun 2026)

agent_long_horizon (multi-step): 12 tests con conversaciones de 8+ turnos. Mide context retention, skill orchestration, interruption recovery, goal persistence. Plantilla rígida (script de usuario pre-escrito) para reproducibilidad. Tools simulados via stubs.

NIAH-ES v3 (Needle-in-a-Haystack en español): rediseñada en junio con **needles neutros** (no secretos) y grilla **8K–800K**, cada modelo medido hasta su context window real. Reporta contexto USABLE + curva por tamaño (no un agregado engañoso). Ver los 5 hallazgos de por qué la versión vieja mentía.

prompt_injection_es (seguridad, NUEVA): secreto plantado en un documento + se pide extraerlo. Premia rehusar, penaliza filtrar. Mide resistencia a fuga de credenciales (Opus 4.8 rehúsa, los cheap filtran).

Que SI medimos

- ✓ **Calidad** (70%): formato + sustancia + LLM-as-Judge Phi-4 14B local
- ✓ **Costo real** (15%): por provider exacto, curva log inversa
- ✓ **Velocidad** (7.5%): tokens por segundo
- ✓ **Latencia** (7.5%): primer token (medida desde Chile)
- ✓ **Tool calling** (badge, no pesa el score): function calling para agentes
- ✓ Multi-turn long-horizon (8+ turnos)
- ✓ Long-context retrieval hasta 800K (contexto usable, dimensión aparte)

Que NO medimos

- ✗ Debugging agentic real (Docker/K8s) — usa **SWE-bench Verified**
- ✗ Capacidades fundamentales generales — usa **HumanEval/MMLU/GSM8K**
- ✗ Multimodal (imágenes/audio) — limitado
- ✗ Consistencia entre runs (single shot N=1)
- ✗ Razonamiento puro complejo — usa **GPQA Diamond/AIME**

† **Recordatorio:** este benchmark es **complemento**, no sustituto. Para producción aplicada en español neutro LATAM agrega data que los académicos no cubren. Para investigación académica, prioriza los oficiales.

Metodología completa + reproducibilidad: <https://github.com/ctala/ai-benchmarks-alternativos/blob/main/CLAUDE.md>

¿Te sirvió este cheatsheet?

Llévatelo a producción, aporta datos o únete a la comunidad



Calculadora interactiva

[https://
benchmarks.cristiantala.com/](https://benchmarks.cristiantala.com/)

Filtra por presupuesto, calidad, velocidad. Top 100 modelos actualizados.



Comunidad Skool

[https://www.skool.com/cagala-
aprende-repite/about](https://www.skool.com/cagala-aprende-repite/about)

Cágala, Aprende, Repite —
workshops, casos reales, stack de
emprendedores LATAM.

Cómo aportar al benchmark

- 1. Reporta tu caso real** · ¿Modelo X resolvió/falló en tu producción? Compártelo en la comunidad o GitHub Issues.
- 2. Sugiere tests nuevos** · El benchmark es open-source MIT. Pull requests bienvenidos.
- 3. Replica los benchmarks** · Repo público, datos crudos versionados, scripts reproducibles.
- 4. Comparte hallazgos** · Si encontrás un patrón en tu uso, documentalo en INSIGHTS.md.

github.com/ctala/ai-benchmarks-alternativos

cristiantala.com · Septiembre 2026 · v4.13.0 · MIT

Este benchmark se mantiene gracias a tiempo personal de Cristian Tala Sánchez (Chile) + ~\$300/mes en suscripciones simultáneas (Xiaomi, MiniMax, Claude, Ollama Cloud) y gasto continuo de OpenRouter para las actualizaciones. Si te ayudó, comparte el repo. Si querés contribuir, las contribuciones de comunidad se documentan en CHANGELOG.