

// BENCHMARK DE MODELOS AI

AI Model Benchmark

Executive Brief para emprendedores hispanohablantes

Julio 2026



Calculadora



Repo + datos

// TOP 3 MODELOS DEL MES

#1

DeepSeek V4 Pro (Ollama Cloud) EMERGENTE

8.84

ollama_cloud · quality 9.85 · 10 runs

#2

DeepSeek V4 Flash (OpenRouter)

8.33

openrouter · quality 8.34 · 133 runs

#3

DeepSeek R1 (reasoning)

8.28

openrouter · quality 8.69 · 103 runs

94

MODELOS TESTEADOS

145

EN CATÁLOGO

10,860+

RUNS REALES

26

SUITES

91

TESTS PRÁCTICOS

Medido desde Santiago, Chile · v3.0 · MIT · Datos abiertos · PRs y sugerencias bienvenidas en el repo.
Hecho con tests reales, cafeína y feedback de la comunidad hispanohablante.

Top 12 modelos

#1	DeepSeek V4 Pro (Ollama Cloud)		8.84
#2	DeepSeek V4 Flash (OpenRouter)		8.33
#3	DeepSeek R1 (reasoning)		8.28
#4	Qwen3-Coder-Next (OpenRouter FP8)		8.13
#5	Claude Opus 4.8 (suscripción)		8.10
#6	DeepSeek V4 Flash (Ollama Cloud)		8.08
#7	Devstral Small		8.01
#8	Claude Haiku 4.5 (suscripción)		8.00
#9	Gemini 3.1 Flash Lite (thinking)		7.97
#10	Claude Sonnet 4.6 (suscripción)		7.92
#11	MiniMax M3 (directo / sub)		7.83
#12	Qwen 3.6 Max		7.83

Score compuesto v3.0: quality 70% + costo 15% + velocidad 7.5% + latencia 7.5%.

Insights del mes

Mejor open-source: DeepSeek V4 Pro (Ollama Cloud) EMERGENTE (8.84) — opción sin vendor lock-in.

Mejor relación calidad/precio: DeepSeek V4 Pro (Ollama Cloud) EMERGENTE — score 8.84 a gratis.

Mas rapido: GPT-OSS 20B (Groq) a 633 tok/s.

Seguridad: Claude Sonnet 4.6 (suscripción) lidera prompt-injection (7.44); modelos cheap filtran ~2.0.

Nuevos este mes

Grok 4.3 entra con score oficial 2.54 (metodologia v3.0 z-score; calidad promedio, costo elevado).

Nemotron 3 Ultra 550B ahora en OpenRouter: score 6.17 y costo competitivo.

North Mini Code quedo fuera de este lanzamiento por falta de endpoint de pago estable en OpenRouter.

Qué modelo usar

Coding

Devstral Small

Score coding 8.52 · gratis

- + Lidera la categoría con el score mas alto en coding del benchmark.
- + Es open-source y Gratis para volumen moderado; ideal para plugins, scripts y tareas atomicas.
- No usamos Qwen3-Coder-Next (#3 global, score 8.13) porque cuesta y Devstral Small cubre la mayoría de tareas de código. Opus 4.8 es overkill y requiere suscripción para coding atomico.

Alternativas: Gemini 2.5 Flash Lite, Llama 4 Scout 17B (Groq preview)

Agentes / Operaciones

Llama 3.1 8B Instant (Groq)

Score agentes 7.88 · gratis

- + Mejor score en tool calling, orquestacion y workflows operativos.
- + 367 tok/s para respuestas sincronicas con el usuario final.
- No usamos Claude Haiku 4.5 (score agentes 7.85) porque requiere suscripción de Anthropic; Llama 3.1 8B Instant (Groq) entrega latencia baja sin costo fijo.

Alternativas: Claude Haiku 4.5 (suscripción), Qwen3-Coder-Next (OpenRouter FP8)

Contenido / Marketing

GPT-OSS 20B (Groq)

Score contenido 8.43 · gratis

- + Lidera la categoría con el mejor score en generacion de contenido en espanol.
- + Tono natural para copy, newsletters y redes sociales sin sonar robotico.
- No usamos Llama 4 Scout (score contenido 8.35) porque GPT-OSS 20B (Groq) es mas rapido y tambien gratis/eficiente.

Alternativas: Llama 4 Scout 17B (Groq preview), Llama 3.1 8B Instant (Groq)

Razonamiento / Analisis

Devstral Small

Score razonamiento 8.39 · gratis

- + Mejor score en analisis de negocio, resúmenes ejecutivos y toma de decisiones con datos.
- + No somos solo un benchmark de código: razonamiento, contenido y agentes pesan igual.
- No usamos Claude Opus 4.8 ni DeepSeek R1 para razonamiento estandar porque Devstral Small es suficiente y evita el costo premium.

Alternativas: Llama 4 Scout 17B (Groq preview), DeepSeek V4 Flash (OpenRouter)

Top 5 por pilar

Razonamiento			Coding			Contenido		
#1	Devstral Small	8.39	#1	Devstral Small	8.52	#1	GPT-OSS 20B (Groq)	8.43
#2	Llama 4 Scout 17B (Groq pr	8.38	#2	Gemini 2.5 Flash Lite	8.32	#2	Llama 4 Scout 17B (Groq pr	8.35
#3	DeepSeek V4 Flash (OpenRou	8.19	#3	Llama 4 Scout 17B (Groq pr	8.20	#3	Llama 3.1 8B Instant (Groq	8.33
#4	Gemini 3.1 Flash Lite	8.15	#4	DeepSeek V4 Flash (OpenRou	8.08	#4	DeepSeek V4 Flash (OpenRou	8.28
#5	Grok 4.1 Fast	8.09	#5	Qwen3-Coder-Next (OpenRout	8.08	#5	Qwen3-Coder-Next (OpenRout	8.25

Agentes		
#1	Llama 3.1 8B Instant (Groq	7.88
#2	Claude Haiku 4.5 (suscripc	7.85
#3	Qwen3-Coder-Next (OpenRout	7.76
#4	DiffusionGemma 26B-A4B (DG	7.76
#5	Qwen 3.6 35B base (OpenRou	7.69

// BADGES ESPECIALES

Top global: DeepSeek V4 Pro (Ollama Cloud)

Mejor calidad: DeepSeek V4 Pro (Ollama Cloud)

Mas rapido: GPT-OSS 20B (Groq) (633 tok/s)

Seguridad: Claude Sonnet 4.6 (suscripción)

NIAH: Claude Haiku 4.5 (suscripción)

Open-source: DeepSeek V4 Pro (Ollama Cloud)

// PROVEEDORES Y COSTOS

Mapa de proveedores

Provider	Tipo	Modelos clave	Costo	Notas
NVIDIA NIM	Free tier	DeepSeek V4 Flash, Gemma 4, Nemotron, Qwen 3-Next	\$0	40 RPM, ideal para bajo volumen
Xiaomi MiMo	Sub	MiMo V2.5 family	\$14/mes	Español neutro fuerte
MiniMax	Sub / API	M2.7 Highspeed	\$19/mes o \$0.30/\$1.20	Ultra baja latencia
Ollama Cloud	Sub	GPT-OSS 120B, DeepSeek V4, Qwen 3.5	\$30/mes	5 modelos, alta fiabilidad
OpenRouter	Aggregator	290+ modelos	Variable	1 API key, fallback automático
OpenAI / Anthropic / Google	API directa	GPT, Claude, Gemini	Premium	Mejor calidad, costo alto

Estrategia recomendada: 1 sub barata (MiMo \$14) para producción base + NVIDIA NIM gratis para modelos especializados + OpenRouter con \$20-50 de crédito como fallback.

// ESTRATEGIA POR PRESUPUESTO

~\$0/mes: NIM gratis + Groq cheap + modelos locales.

~\$30-50/mes: MiMo + Ollama Cloud + NIM.

// METODOLOGÍA V3.0

Cómo se calcula el score global

- 70%** Calidad (formato + sustancia + LLM-as-Judge Phi-4 14B)
- 15%** Costo (por provider exacto, curva inversa)
- 7.5%** Velocidad (tokens por segundo)
- 7.5%** Latencia (primer token, medido desde Chile)
- badge** Tool calling y seguridad se muestran como badges, no entran en el compuesto

91 tests prácticos en español + long-context NIAH-ES + seguridad prompt_injection_es.
Este benchmark es complemento, no sustituto de HumanEval, MMLU, SWE-bench, LMSYS Arena.



Calculadora



Repo + datos

Hecho con tests reales, cafeína y feedback de la comunidad hispanohablante.
PRs, issues y sugerencias bienvenidas en <https://github.com/ctala/ai-benchmarks-alternativos>