

// BENCHMARK DE MODELOS AI

AI Model Benchmark

Executive Brief para emprendedores hispanohablantes

Julio 2026

// TOP 3 MODELOS DEL MES



Calculadora



Repo + datos

#1

DeepSeek V4 Flash
(OpenRouter)

8.33

openrouter · quality 8.34 · 133 runs

#2

DeepSeek R1 (reasoning)

8.27

openrouter · quality 8.69 · 103 runs

#3

DeepSeek V4 Pro (Ollama
Cloud) EMERGENTE

8.19

ollama_cloud · quality 9.85 · 10 runs

94

MODELOS TESTEADOS

145

EN CATÁLOGO

10,853+

RUNS REALES

26

SUITES

91

TESTS PRÁCTICOS

Medido desde Santiago, Chile · v3.0 · MIT · Datos abiertos · PRs y sugerencias bienvenidas en el repo.
Hecho con tests reales, cafeína y feedback de la comunidad hispanohablante.

Top 12 modelos

#1	DeepSeek V4 Flash (OpenRouter)		8.33
#2	DeepSeek R1 (reasoning)		8.27
#3	DeepSeek V4 Pro (Ollama Cloud)		8.19
#4	Qwen3-Coder-Next (OpenRouter FP8)		8.13
#5	Claude Opus 4.8 (suscripción)		8.10
#6	Llama 3.3 70B (Groq)		8.05
#7	Claude Haiku 4.5 (suscripción)		8.00
#8	Devstral Small		8.00
#9	Gemini 3.1 Flash Lite (thinking)		7.97
#10	Claude Sonnet 4.6 (suscripción)		7.91
#11	MiniMax M3 (directo / sub)		7.83
#12	Qwen 3.6 Max		7.83

Score compuesto v3.0: quality 70% + costo 15% + velocidad 7.5% + latencia 7.5%.

Insights del mes

- Mejor open-source:** DeepSeek V4 Flash (OpenRouter) (8.33) — opción sin vendor lock-in.
- Mejor relación calidad/precio:** Mistral Nemo — score 2.79 a \$0.000036/call.
- Mas rapido:** GPT-OSS 20B (Groq) a 633 tok/s.
- Seguridad:** Claude Sonnet 4.6 (suscripción) lidera prompt-injection (7.44); modelos cheap filtran ~2.0.
- Nuevos este mes**
- Grok 4.3** entra con score oficial 2.54 (metodologia v3.0 z-score; calidad promedio, costo elevado).
- Nemotron 3 Ultra 550B** ahora en OpenRouter: score 6.17 y costo competitivo.
- North Mini Code** quedo fuera de este lanzamiento por falta de endpoint de pago estable en OpenRouter.

Qué modelo usar

Coding

Devstral Small

Score coding 8.52 · \$0.000480/call

- + Lidera la categoría con el score mas alto en coding del benchmark.
- + Es open-source y Costo ultra bajo en OpenRouter; ideal para plugins, scripts y tareas atomicas.
- No usamos Qwen3-Coder-Next (#3 global, score 8.13) porque cuesta y Devstral Small cubre la mayoría de tareas de código. Opus 4.8 es overkill y requiere suscripción para coding atomico.

Alternativas: Gemini 2.5 Flash Lite, Llama 4 Scout 17B (Groq preview)

Agentes / Operaciones

Llama 3.1 8B Instant (Groq)

Score agentes 7.88 · \$0.000135/call

- + Mejor score en tool calling, orquestacion y workflows operativos.
- + 367 tok/s para respuestas sincronicas con el usuario final.
- No usamos Claude Haiku 4.5 (score agentes 7.85) porque requiere suscripción de Anthropic; Llama 3.1 8B Instant (Groq) entrega latencia baja sin costo fijo.

Alternativas: Claude Haiku 4.5 (suscripción), Qwen3-Coder-Next (OpenRouter FP8)

Contenido / Marketing

GPT-OSS 20B (Groq)

Score contenido 8.43 · \$0.000472/call

- + Lidera la categoría con el mejor score en generacion de contenido en espanol.
- + Tono natural para copy, newsletters y redes sociales sin sonar robotico.
- No usamos Llama 4 Scout (score contenido 8.35) porque GPT-OSS 20B (Groq) es mas rapido y mantiene un costo competitivo en su provider.

Alternativas: Llama 3.3 70B (Groq), Llama 4 Scout 17B (Groq preview)

Razonamiento / Analisis

Devstral Small

Score razonamiento 8.39 · \$0.000480/call

- + Mejor score en analisis de negocio, resúmenes ejecutivos y toma de decisiones con datos.
- + No somos solo un benchmark de código: razonamiento, contenido y agentes pesan igual.
- No usamos Claude Opus 4.8 ni DeepSeek R1 para razonamiento estandar porque Devstral Small es suficiente y evita el costo premium.

Alternativas: Llama 4 Scout 17B (Groq preview), DeepSeek V4 Flash (OpenRouter)

// RANKINGS POR CATEGORÍA

Top 5 por pilar

Razonamiento			Coding			Contenido		
#1	Devstral Small	8.39	#1	Devstral Small	8.52	#1	GPT-OSS 20B (Groq)	8.43
#2	Llama 4 Scout 17B (Groq pr	8.38	#2	Gemini 2.5 Flash Lite	8.32	#2	Llama 3.3 70B (Groq)	8.38
#3	DeepSeek V4 Flash (OpenRou	8.19	#3	Llama 4 Scout 17B (Groq pr	8.20	#3	Llama 4 Scout 17B (Groq pr	8.35
#4	Gemini 3.1 Flash Lite	8.15	#4	DeepSeek V4 Flash (OpenRou	8.08	#4	Llama 3.1 8B Instant (Groq	8.33
#5	Llama 3.3 70B (Groq)	8.11	#5	Qwen3-Coder-Next (OpenRout	8.08	#5	DeepSeek V4 Flash (OpenRou	8.28

Agentes		
#1	Llama 3.1 8B Instant (Groq	7.88
#2	Claude Haiku 4.5 (suscripc	7.85
#3	Qwen3-Coder-Next (OpenRout	7.76
#4	DiffusionGemma 26B-A4B (DG	7.76
#5	Qwen 3.6 35B base (OpenRou	7.69

// BADGES ESPECIALES

Top global: DeepSeek V4 Flash (OpenRouter)

Mejor calidad: DeepSeek V4 Pro (Ollama Cloud)

Mas rapido: GPT-OSS 20B (Groq) (633 tok/s)

Seguridad: Claude Sonnet 4.6 (suscripción)

NIAH: Claude Haiku 4.5 (suscripción)

Open-source: DeepSeek V4 Flash (OpenRouter)

Mapa de proveedores

Provider	Tipo	Modelos clave	Costo	Notas
NVIDIA NIM	Free tier	DeepSeek V4 Flash, Gemma 4, Nemotron, Qwen 3-Next	\$0	40 RPM, ideal para bajo volumen
Xiaomi MiMo	Sub	MiMo V2.5 family	\$14/mes	Español neutro fuerte
MiniMax	Sub / API	M2.7 Highspeed, M3	\$19/mes o \$0.30/\$1.20	Ultra baja latencia
Kimi Code	Sub / API	Kimi K2.7 Code, Kimi K2.5	Variable	Muy fuerte en coding y agentes multi-turn
Ollama Cloud	Sub	GPT-OSS 120B, DeepSeek V4, Qwen 3.5	\$30/mes	5 modelos, alta fiabilidad
OpenRouter	Aggregator	290+ modelos	Variable	1 API key, fallback automático
OpenAI / Anthropic / Google	API directa	GPT, Claude, Gemini	Premium	Mejor calidad, costo alto

Estrategia recomendada: 1 sub barata (MiMo \$14) para producción base + NVIDIA NIM gratis para modelos especializados + OpenRouter con \$20-50 de crédito como fallback.

~\$0/mes: NIM gratis + Groq cheap + modelos locales.

~\$30-50/mes: MiMo + Ollama Cloud + NIM.

// METODOLOGÍA V3.0

Cómo se calcula el score global

- 70%** Calidad (formato + sustancia + LLM-as-Judge Phi-4 14B)
- 15%** Costo (por provider exacto, curva inversa)
- 7.5%** Velocidad (tokens por segundo)
- 7.5%** Latencia (primer token, medido desde Chile)
- badge** Tool calling y seguridad se muestran como badges, no entran en el compuesto

91 tests prácticos en español + long-context NIAH-ES + seguridad prompt_injection_es.
Este benchmark es complemento, no sustituto de HumanEval, MMLU, SWE-bench, LMSYS Arena.



Calculadora



Repo + datos

Hecho con tests reales, cafeína y feedback de la comunidad hispanohablante.
PRs, issues y sugerencias bienvenidas en <https://github.com/ctala/ai-benchmarks-alternativos>