

// BENCHMARK DE MODELOS AI

# AI Model Benchmark



benchmarks.cristiantala.com

Executive Brief para emprendedores hispanohablantes

Julio 2026

// TOP 3 MODELOS DEL MES

#1

DeepSeek V4 Flash  
(OpenRouter)

8.33

openrouter · quality 8.34

#2

DeepSeek R1 (reasoning)

8.28

openrouter · quality 8.69

#3

Qwen3-Coder-Next  
(OpenRouter FP8)

8.13

openrouter · quality 8.22

94

MODELOS TESTEADOS

145

EN CATÁLOGO

10,853+

RUNS REALES

26

SUITES

91

TESTS PRÁCTICOS

Medido desde Santiago, Chile · v3.0 · MIT · Datos abiertos en [github.com/ctala/ai-benchmarks-alternativos](https://github.com/ctala/ai-benchmarks-alternativos)

# Top 10 modelos

|     |                                   |             |      |
|-----|-----------------------------------|-------------|------|
| #1  | DeepSeek V4 Flash (OpenRouter)    | <div></div> | 8.33 |
| #2  | DeepSeek R1 (reasoning)           | <div></div> | 8.28 |
| #3  | Qwen3-Coder-Next (OpenRouter FP8) | <div></div> | 8.13 |
| #4  | Claude Opus 4.8 (suscripción)     | <div></div> | 8.10 |
| #5  | Devstral Small                    | <div></div> | 8.01 |
| #6  | Claude Haiku 4.5 (suscripción)    | <div></div> | 8.00 |
| #7  | Claude Sonnet 4.6 (suscripción)   | <div></div> | 7.92 |
| #8  | MiniMax M3 (directo / sub)        | <div></div> | 7.83 |
| #9  | Qwen 3.6 Max                      | <div></div> | 7.83 |
| #10 | Llama 4 Scout 17B (Groq preview)  | <div></div> | 7.81 |

Score compuesto v3.0: quality 70% + costo 15% + velocidad 7.5% + latencia 7.5%.

## Insights del mes

- Mejor open-source:** DeepSeek V4 Flash (OpenRouter) (8.33) — opción sin vendor lock-in.
- Mejor relación calidad/precio:** DeepSeek V4 Flash (OpenRouter) — score 8.33 a gratis.
- Mas rapido:** GPT-OSS 20B (Groq) a 633 tok/s.
- Seguridad:** Claude Sonnet 4.6 (suscripción) lidera prompt-injection (7.44); modelos cheap filtran ~2.0.
- Nuevos este mes**
- Grok 4.3** entra con score oficial 2.54 (metodologia v3.0 z-score; calidad promedio, costo elevado).
- Nemotron 3 Ultra 550B** ahora en OpenRouter: score 6.17 y costo competitivo.
- North Mini Code** quedo fuera de este lanzamiento por falta de endpoint de pago estable en OpenRouter.

## Qué modelo usar

### Coding

#### Devstral Small

Score coding 8.52 · gratis

**Alternativas:** Gemini 2.5 Flash Lite, Llama 4 Scout 17B (Groq preview)

### Agentes / Operaciones

#### Llama 3.1 8B Instant (Groq)

Score agentes 7.88 · gratis

**Alternativas:** Claude Haiku 4.5 (suscripción), Qwen3-Coder-Next (OpenRouter FP8)

### Contenido / Marketing

#### GPT-OSS 20B (Groq)

Score contenido 8.43 · gratis

**Alternativas:** Llama 4 Scout 17B (Groq preview), Llama 3.1 8B Instant (Groq)

### Mejor costo/beneficio

#### DeepSeek V4 Flash (OpenRouter)

Score 8.33 · gratis

**Si necesitas gratis:** DeepSeek V4 Flash (OpenRouter) (gratis)

Recomendaciones detalladas por presupuesto en el repo

// RANKINGS POR CATEGORÍA

# Top 5 por pilar

| Razonamiento |                            |      | Coding |                            |      | Contenido |                            |      |
|--------------|----------------------------|------|--------|----------------------------|------|-----------|----------------------------|------|
| #1           | Devstral Small             | 8.39 | #1     | Devstral Small             | 8.52 | #1        | GPT-OSS 20B (Groq)         | 8.43 |
| #2           | Llama 4 Scout 17B (Groq pr | 8.38 | #2     | Gemini 2.5 Flash Lite      | 8.32 | #2        | Llama 4 Scout 17B (Groq pr | 8.35 |
| #3           | DeepSeek V4 Flash (OpenRou | 8.19 | #3     | Llama 4 Scout 17B (Groq pr | 8.20 | #3        | Llama 3.1 8B Instant (Groq | 8.33 |
| #4           | Gemini 3.1 Flash Lite      | 8.15 | #4     | DeepSeek V4 Flash (OpenRou | 8.08 | #4        | DeepSeek V4 Flash (OpenRou | 8.28 |
| #5           | Grok 4.1 Fast              | 8.09 | #5     | Qwen3-Coder-Next (OpenRout | 8.08 | #5        | Qwen3-Coder-Next (OpenRout | 8.25 |

| Agentes |                            |      |
|---------|----------------------------|------|
| #1      | Llama 3.1 8B Instant (Groq | 7.88 |
| #2      | Claude Haiku 4.5 (suscripc | 7.85 |
| #3      | Qwen3-Coder-Next (OpenRout | 7.76 |
| #4      | DiffusionGemma 26B-A4B (DG | 7.76 |
| #5      | Qwen 3.6 35B base (OpenRou | 7.69 |

// BADGES ESPECIALES

Top global: DeepSeek V4 Flash (OpenRouter)

Mejor calidad: DeepSeek R1 (reasoning)

Mas rapido: GPT-OSS 20B (Groq) (633 tok/s)

Seguridad: Claude Sonnet 4.6 (suscripción)

NIAH: Claude Haiku 4.5 (suscripción)

Open-source: DeepSeek V4 Flash (OpenRouter)

// PROVEEDORES Y COSTOS

# Mapa de proveedores

| Provider                    | Tipo        | Modelos clave                                     | Costo                    | Notas                           |
|-----------------------------|-------------|---------------------------------------------------|--------------------------|---------------------------------|
| NVIDIA NIM                  | Free tier   | DeepSeek V4 Flash, Gemma 4, Nemotron, Qwen 3-Next | \$0                      | 40 RPM, ideal para bajo volumen |
| Xiaomi MiMo                 | Sub         | MiMo V2.5 family                                  | \$14/mes                 | Español neutro fuerte           |
| MiniMax                     | Sub / API   | M2.7 Highspeed                                    | \$19/mes o \$0.30/\$1.20 | Ultra baja latencia             |
| Ollama Cloud                | Sub         | GPT-OSS 120B, DeepSeek V4, Qwen 3.5               | \$30/mes                 | 5 modelos, alta fiabilidad      |
| OpenRouter                  | Aggregator  | 290+ modelos                                      | Variable                 | 1 API key, fallback automático  |
| OpenAI / Anthropic / Google | API directa | GPT, Claude, Gemini                               | Premium                  | Mejor calidad, costo alto       |

**Estrategia recomendada:** 1 sub barata (MiMo \$14) para producción base + NVIDIA NIM gratis para modelos especializados + OpenRouter con \$20-50 de crédito como fallback.

// ESTRATEGIA POR PRESUPUESTO

**~\$0/mes:** NIM gratis + Groq cheap + modelos locales.

**~\$30-50/mes:** MiMo + Ollama Cloud + NIM.

// METODOLOGÍA V3.0

### Cómo se calcula el score global

|       |                                                                             |
|-------|-----------------------------------------------------------------------------|
| 70%   | Calidad (formato + sustancia + LLM-as-Judge Phi-4 14B)                      |
| 15%   | Costo (por provider exacto, curva inversa)                                  |
| 7.5%  | Velocidad (tokens por segundo)                                              |
| 7.5%  | Latencia (primer token, medido desde Chile)                                 |
| badge | Tool calling y seguridad se muestran como badges, no entran en el compuesto |

91 tests prácticos en español + long-context NIAH-ES + seguridad prompt\_injection\_es.  
Este benchmark es complemento, no sustituto de HumanEval, MMLU, SWE-bench, LMSYS Arena.



[benchmarks.cristiantala.com](https://benchmarks.cristiantala.com)

Filtrá por presupuesto, calidad, velocidad y caso de uso.  
Datos abiertos: <https://github.com/ctala/ai-benchmarks-alternativos>